



多模态人工智能系统
全国重点实验室
State Key Laboratory of
Multimodal Artificial Intelligence Systems

MAIS

计算机视觉

深度学习与局部特征提取

董秋雷

中国科学院自动化研究所

多模态人工智能系统全国重点实验室



计算机视觉的研究目标与主题

- 计算机视觉的研究目标：使计算机具有通过一幅或多幅图像认知周围环境信息的能力。
- 计算机视觉学科涉及的研究主题：特征提取与匹配、图像分割、目标识别、三维重建、视觉跟踪、行为分析……





目 录


一、深度学习概述

二、局部特征提取



关于深度学习

- 深度学习：机器学习的一个分支，旨在利用多层人工神经网络对数据进行自动学习。
- 美国《麻省理工评论》评选出2013年度10大突破性技术,深度学习(Deep Learning)居首，目前最为流行的计算技术。
- 在图像识别、图像分割等诸多视觉任务都取得了目前最好的识别结果。



深度学习的发展历史


人工神经网络

浅层学习

深度学习

生物神经元与 MP 模型

生物神经元	神经元	输入信号	权值	输出	总和	膜电位	阈值
MP 模型	j	x_i	ω_{ij}	o_j	$\sum$	$\sum_{i=1}^n \omega_{ij} x_i(t)$	T_j




深度学习的发展历史


神经网络

浅层学习

深度学习



1943年, Mcculloch 和 Pitts提出神经元的数学模型;




$$y_k = \phi\left(\sum_{i=1}^m w_{ki}x_i - b_k\right)$$

深度学习的发展历史

神经网络

浅层学习

深度学习



50 年代末，Rosenblatt 提出了感知机模型；



1943年，Mcculloch 和 Pitts 提出神经元的数学模型；

深度学习的发展历史

神经网络


浅层学习

深度学习



50 年代末，Rosenblatt 提出了感知机模型；

1943年，Mcculloch 和 Pitts 提出神经元的数学模型；




深度学习的发展历史

神经网络


浅层学习

深度学习

80年代末期，BP算法
(再次) 提出。



50年代末，Rosenblatt
提出了感知机模型；



1943年，Mcculloch 和
Pitts提出神经元的数学
模型；


深度学习的发展历史

神经网络


浅层学习

深度学习

90年代，SVM、 Boosting、 最大熵方法等方法相继被提出



$$y = f(input)$$








深度学习的发展历史

人工神经网络

浅层学习

深度学习

2006年, Hinton等“重新发掘”深度神经网络




深度学习的发展历史

2012年, AlexNet取得ILSVRC-2012竞赛冠军


VGG

•2014年, 卷积模块




ResNet

•2015年, 残差模块



Transformer

•2017年NLP、2020年CV, 自注意力模块



多模态大模型.....

深度学习的部分代表人物



AWARD WINNER

Geoffrey E Hinton

ACM A. M. Turing Award (2018)

2018 ACM A.M. Turing Award



AWARD WINNER

Yoshua Bengio

ACM A. M. Turing Award (2018)

2018 ACM A.M. Turing Award



AWARD WINNER

Yann LeCun


ACM A. M. Turing Award (2018)

2018 ACM A.M. Turing Award

深度学习的常用模型




多层感知机 (MLP, Multi-Layer Perception) :

- 隐含层通常均为全连接层。
- 全连接层：每一个神经元均与上一层的所有神经元存在连接关系。



深度学习的常用模型


深度玻尔兹曼机：基于受限玻尔兹曼机(RBM, Restricted Boltzmann Machine)的深度神经网络。



深度学习的常用模型

深度卷积神经网络(Convolutional Neural Networks): 第一个真正成功训练的多层网络结构


3 6 8 1 7 9 6 6 9 1
6 7 5 7 8 6 3 4 8 5
2 1 7 9 7 1 2 8 4 5
4 8 1 9 0 1 8 8 9 4
7 6 1 8 6 4 1 5 6 0
7 5 9 2 6 5 8 1 9 7
2 2 2 2 2 3 4 4 8 0
0 2 3 8 0 7 3 8 5 7
0 1 4 6 4 6 0 2 4 3
7 1 2 8 9 6 9 8 6 1



CNN基本结构

CNN基本网络:


- 输入层、卷积层、激活层、池化层、全连接层




CNN—全连接与局部连接

全连接层所面临的问题：

- 当输入、输出维度较高时，全连接层所需的参数量过于庞大。



二维卷积



- 卷积是在信号处理领域中的一个基本概念
- 二维连续函数的卷积:

$$g(x, y) * f(x, y) = \int_{\tau_1=-\infty}^{\infty} \int_{\tau_2=-\infty}^{\infty} g(\tau_1, \tau_2) f(x - \tau_1, y - \tau_2) d\tau_1 d\tau_2$$

其中, $g(x, y)$: 核函数


- 二维离散函数的卷积:

$$G(x, y) * I(x, y) = \sum_{u=-M}^M \sum_{v=-N}^N G(u, v) I(x - u, y - v)$$

其中, $G(x, y)$: 尺寸为 $(2M + 1) \times (2N + 1)$ 的模板


图像卷积

- 二维图像的卷积：将像素及其相邻像素的值与某个矩阵（卷积核）做卷积运算




图像卷积

- 二维图像的卷积：将像素及其相邻像素的值与某个矩阵（卷积核）做卷积运算




图像卷积

- 二维图像的卷积：将像素及其相邻像素的值与某个矩阵（卷积核）做卷积运算




图像卷积

- 二维图像的卷积：将像素及其相邻像素的值与某个矩阵（卷积核）做卷积运算




图像卷积

- 二维图像的卷积：将像素及其相邻像素的值与某个矩阵（卷积核）做卷积运算




图像卷积

- 二维图像的卷积：将像素及其相邻像素的值与某个矩阵（卷积核）做卷积运算




图像卷积

- 二维图像的卷积：将像素及其相邻像素的值与某个矩阵（卷积核）做卷积运算




图像卷积

- 二维图像的卷积：将像素及其相邻像素的值与某个矩阵（卷积核）做卷积运算



图像卷积

- 二维图像的卷积：将像素及其相邻像素的值与某个矩阵（卷积核）做卷积运算







图像卷积示例



*



不同的高斯核



CNN—权值共享

权值共享：


- 功能：在图像或特征图上进行卷积计算时，图像或特征图的所有像素区域共享一个滤波器的权重。
- 作用：降低网络参数数量。



CNN—多核卷积


多核卷积：

- 功能：采用多个卷积核对特征图进行卷积计算，输出的特征图的通道数目等于卷积核的个数。
- 作用：兼顾特征表达能力与网络参数量。



CNN—多核卷积

- 多核卷积示例



CNN中常用的激活函数


激活函数：通常用于卷积层/全连接层之后

- 旨在引入非线性变换，以利于学习复杂的数据特征。
- 若无激活函数，则整个卷积网络均为线性操作。


常用的激活函数

- Sigmoid函数
- Tanh函数
- ELU
- Maxout
- ReLU (Rectified Linear Unit)
- Leaky ReLU

$$S(x) = \frac{1}{1 + e^{-x}}$$




$$f(x) = \max(0, x),$$



CNN—Pooling(池化)

池化层：通常在卷积层之后加入一个池化层

- 功能：对输入特征图进行数据压缩。
- 特点：在不同的特征通道上分开执行，即池化操作不改变通道数，且不需要参数控制。
- 作用：特征降维/降低计算、防止过拟合等。





注意：subsampling不等同于Pooling！

CNN—Pooling(池化)

常用的池化方式：


- 最大池化：选择邻域内元素最大值作为输出值。
- 平均池化：计算邻域内元素平均值作为输出值。






CNN—Pooling(池化)

池化的邻域尺寸选择：通常是手工设置。



Convolved
feature




Pooled
feature

MAIS



CNN再回顾




MAIS



深度神经网络的训练

网络训练：利用训练数据自动地学习网络参数的过程。

训练数据：预先给定的数据（在有监督条件下，数据的标签也是已知的）



深度神经网络的训练

网络训练：利用训练数据自动地学习网络参数的过程。

训练数据：预先给定的数据（在有监督条件下，数据的标签也是已知的）。




3	6	8	1	7	9	6	6	9	1
6	7	5	7	8	6	3	4	8	5
2	1	7	9	7	1	2	8	4	5
4	8	1	9	0	1	8	8	9	4
7	6	1	8	6	4	1	5	6	0
7	5	9	2	6	5	8	1	9	7
2	2	2	2	2	3	4	4	8	0
0	2	3	8	0	7	3	8	5	7
0	1	4	6	4	6	0	2	4	3
7	1	2	8	9	6	9	8	6	1

0	->>	[1, 0, 0, 0, 0, 0, 0, 0, 0, 0]
1	->>	[0, 1, 0, 0, 0, 0, 0, 0, 0, 0]
2	->>	[0, 0, 1, 0, 0, 0, 0, 0, 0, 0]
3	->>	[0, 0, 0, 1, 0, 0, 0, 0, 0, 0]
4	->>	[0, 0, 0, 0, 1, 0, 0, 0, 0, 0]
5	->>	[0, 0, 0, 0, 0, 1, 0, 0, 0, 0]
6	->>	[0, 0, 0, 0, 0, 0, 1, 0, 0, 0]
7	->>	[0, 0, 0, 0, 0, 0, 0, 1, 0, 0]
8	->>	[0, 0, 0, 0, 0, 0, 0, 0, 1, 0]
9	->>	[0, 0, 0, 0, 0, 0, 0, 0, 0, 1]

深度神经网络的训练

给定含标签的数据集，深度网络参数的学习问题本质上是一个复杂非线性函数的拟合问题。



$$Label = g(x) \longrightarrow \min d(Label, g(x))$$



典型深度网络

- AlexNet
- VGG
- GoogleNet
- ResNet
- LSTM -- Long Short-Term Memory
- GAN -- Generative Adversarial Nets
- Transformer
- Diffusion Model

MAIS



- **PyTorch**
 - 2017年，Facebook人工智能研究院基于Torch推出了PyTorch，PyTorch已被越来越广泛地使用。
 - 它是一个开源的Python机器学习库。
 - PyTorch支持GPU、带有高级功能，可以用来搭建和训练深度神经网络。

常用开发平台

- **TensorFlow**

- 开发者：Google Brain Team
- 底层语言：C++ Python
- 接口语言：Python C/C++
- 运行方式：CPU or GPU
- 操作系统：Linux or Mac OS X





目录



一、深度学习概述

二、局部特征提取




图像局部特征提取概述

- 图像局部特征提取
 - 旨在从图像中自动提取出直观或非直观的局部特征。
 - 计算机视觉、图像处理等领域共有的一个研究主题
 - 执行立体匹配、三维重建、物体分类与识别等诸多视觉任务的基础。




图像局部特征提取概述

- 图像局部特征提取
 - 旨在从图像中自动提取出直观或非直观的局部特征。
 - 计算机视觉、图像处理等领域共有的一个研究主题。
 - 执行立体匹配、三维重建、物体分类与识别等诸多视觉任务的基础。



图像局部特征提取概述

- 随着技术的不断发展，根据特征点匹配过程包含的执行阶段数目划分，现有的特征点匹配策略可以粗略地分为三类：三阶段特征点匹配策略、两阶段特征点匹配策略、与单阶段特征点匹配策略。



图像局部特征提取概述

- 图像局部特征提取
 - 旨在从图像中自动提取出直观或非直观的局部特征。
 - 计算机视觉、图像处理等领域共有的一个研究主题
 - 执行立体匹配、三维重建、物体分类与识别等诸多视觉任务的基础。



图像局部特征提取概述

- 图像局部特征提取
 - 旨在从图像中自动提取出直观或非直观的局部特征。
 - 计算机视觉、图像处理等领域共有的一个研究主题
 - 执行立体匹配、三维重建、物体分类与识别等诸多视觉任务的基础。





多模态人工智能系统
全国重点实验室

State Key Laboratory of
Multimodal Artificial Intelligence Systems

MAIS

边缘检测



边缘的物理意义

边缘在哪？




MAIS



边缘的物理意义

图像边缘的产生

- 物体的边界、表面方向的变化、不同的颜色、光照明暗的变化



边缘提取

边缘的定义 (WHAT)

提取边缘的意义 (WHY)

提取边缘的方法 (HOW)




- 使用微分滤波器提取边缘
 - 一阶微分滤波器：梯度算子
 - 二阶微分滤波器：LoG
- Canny算子

边缘的定义

定义：

- “边缘是图像中亮度突然变化的区域。”
- “图像灰度构成的曲面上的陡峭区域。”
- “像素灰度存在阶跃变化或屋脊状变化的像素的集合。”

灰度图像中边缘的类型



为什么要提取边缘?

边缘是最基本的图像特征之一:

- 可以表达物体的特征
- 边缘特征对于图像的变化不敏感
 - 几何变化, 灰度变化, 光照方向变化
- 可以为物体检测提供有用的信息
- 是一种典型的图像预处理过程



如何提取边缘？（灰度图象）

灰度图象边缘提取思路：

- 抑制噪声（低通滤波、平滑、去噪、模糊）
- 边缘特征增强（高通滤波、锐化）
- 边缘定位






图像微分算子

- 一阶微分算子（梯度算子）：Prewitt、Sobel等
 - 检测最大值
- 二阶微分算子：Laplacian
 - 检测过零点

MAIS



微分算子检测边缘：一维信号






一阶导数的极大值点：

$$\text{Edge} = \{x | x = \operatorname{argmax}(f'(x))\}$$

二阶导数的过零点：

$$\text{Edge} = \{x | f''(x) = 0, \text{zero crossing}\}$$



微分算子检测边缘：二维信号

一阶导数的极大值点：

$$\text{Edge} = \{p = (x, y) | p = \operatorname{argmax}(|\nabla I(p)|)\}$$

其中，图像梯度向量： $\nabla I(x, y) = (\frac{\partial I}{\partial x}, \frac{\partial I}{\partial y})$

梯度幅值表示边缘的强弱

梯度方向代表灰度变化最快的方向

$$|\nabla I(x, y)| = \sqrt{(\frac{\partial I}{\partial x})^2 + (\frac{\partial I}{\partial y})^2}$$

$$\Psi(x, y) = \arctan(\frac{\partial I}{\partial y} / \frac{\partial I}{\partial x})$$

微分算子检测边缘：二维信号

二阶导数的过零点：

$$\text{Edge} = \{p = (x, y) | \Delta I(p) = 0, \text{zero crossing}\}$$

拉普拉斯算子：

$$\Delta I = \nabla^2 I = \frac{\partial^2 I}{\partial x^2} + \frac{\partial^2 I}{\partial y^2}$$

在数字图像上计算梯度

- 一维的情况:


$$f'(x) = \frac{df}{dx} = \lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x) - f(x)}{\Delta x}$$

对于离散的数字信号, 可以使用差分近似:

$$f'(x) \approx \frac{f(x + 1) - f(x - 1)}{2}$$

相当于与如下模版进行卷积运算:

$$\begin{bmatrix} -1 & 0 & 1 \end{bmatrix} \times 0.5$$



在数字图像上计算梯度

- 使用差分运算在数值上近似一阶微分运算

$$\frac{\partial I}{\partial x} \approx \frac{f(x+1, y) - f(x-1, y)}{2}$$

 竖直边缘

-1	0	1
----	---	---

 $\times 0.5$

$$\frac{\partial I}{\partial y} \approx \frac{f(x, y+1) - f(x, y-1)}{2}$$

 水平边缘



-1
0
1

 $\times 0.5$

$$\nabla I(x, y) = \left(\frac{\partial I}{\partial x}, \frac{\partial I}{\partial y} \right)$$

噪声的影响：一维信号的例子




从图像中取出某行像素值：




边缘在哪里？



高斯滤波







MAIS






高斯滤波






高斯滤波






高斯滤波






高斯滤波







高斯滤波





高斯滤波






MAIS






高斯滤波




解决方法之一，首先进行滤波


f




h



$h \star f$



$\frac{\partial}{\partial x}(h \star f)$




峰值为边缘的位置


利用卷积运算的性质:

$$\frac{\partial}{\partial x}(h \star f) = (\frac{\partial}{\partial x}h) \star f$$

f




$\frac{\partial}{\partial x}h$



$(\frac{\partial}{\partial x}h) \star f$

峰值为边缘的位置





图像梯度算子的近似

- Sober算子
- Prewitt算子
- Roberts算子

MAIS



Prewitt算子

- Prewitt算子，近似一阶微分
- 卷积模版：去噪 + 增强边缘

-1	0	1
-1	0	1
-1	0	1

←
检测竖直边缘

↓
计算均值，
平滑噪声

-1	-1	-1
0	0	0
1	1	1

←
计算均值，
平滑噪声

↑
检测水
平边缘



Sobel算子

- Sobel算子，近似一阶微分
- 去噪 + 增强边缘，给四邻域更大的权重

-1	0	1
-2	0	2
-1	0	1

检测竖直边缘

计算均值，
平滑噪声

-1	-2	-1
0	0	0
1	2	1

计算均值，
平滑噪声

检测水平边缘

常见的梯度算子

$$\begin{array}{cc} \Delta_1 & \Delta_2 \\ \begin{array}{cc} 0 & 1 \\ -1 & 0 \end{array} & \begin{array}{cc} 1 & 0 \\ 0 & -1 \end{array} \end{array}$$

(a)

$$\begin{array}{cc} \Delta_1 & \Delta_2 \\ \begin{array}{ccc} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{array} & \begin{array}{ccc} 1 & 1 & 1 \\ 0 & 0 & 0 \\ -1 & -1 & -1 \end{array} \end{array}$$

(b)

$$\begin{array}{cc} \Delta_1 & \Delta_2 \\ \begin{array}{ccc} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{array} & \begin{array}{ccc} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{array} \end{array}$$





(c)

$$\begin{array}{cc} \Delta_1 & \Delta_2 \\ \begin{array}{cccc} -3 & -1 & 1 & 3 \\ -3 & -1 & 1 & 3 \\ -3 & -1 & 1 & 3 \\ -3 & -1 & 1 & 3 \end{array} & \begin{array}{cccc} 3 & 3 & 3 & 3 \\ 1 & 1 & 1 & 1 \\ -1 & -1 & -1 & -1 \\ -3 & -3 & -3 & -3 \end{array} \end{array}$$




(d)

Sobel与Prewitt边缘提取示例

Prewitt



Sobel



在数字图像上计算二阶微分

- 拉普拉斯算子 $\Delta I = \nabla^2 I = \frac{\partial^2 I}{\partial x^2} + \frac{\partial^2 I}{\partial y^2}$

- 拉普拉斯算子的数字近似
 - 3*3卷积模版

0	-1	0
-1	4	-1
0	-1	0

-1	-1	-1
-1	8	-1
-1	-1	-1



拉普拉斯算子的特点

- 拉普拉斯算子的运算结果是标量
 - 只有幅值，只使用一个模版便可计算得到
 - 方向属性丢失
- 实际中几乎不单独使用拉普拉斯算子：
 - 二次求导数，对噪声非常敏感
 - 通常配合滤波器同时使用

MAIS



Laplacian of Gaussian (LoG)

- 首先用Gauss函数对图像进行平滑，抑制噪声
- 然后对经过平滑的图像使用Laplacian算子
- 利用卷积的性质LoG算子等效于：


Gaussian平滑 + Laplacian 二阶微分

$$\nabla^2 (G(x, y) \star I(x, y)) = (\nabla^2 G(x, y)) \star I(x, y)$$


高斯拉普拉斯

$$\frac{\partial^2}{\partial x^2}(h \star f)$$


f




$$\frac{\partial^2}{\partial x^2}h$$



$$\left(\frac{\partial^2}{\partial x^2}h\right) \star f$$




二维边缘微分滤波器




高斯

$$h_{\sigma}(u, v) = \frac{1}{2\pi\sigma^2} e^{-\frac{u^2+v^2}{2\sigma^2}}$$



高斯的导数

$$\frac{\partial}{\partial x} h_{\sigma}(u, v)$$





高斯拉普拉斯

$$\nabla^2 h_{\sigma}(u, v)$$

LoG算子:

$$\nabla^2 G(x, y) = - \left[\frac{x^2 + y^2 - \sigma^2}{\sigma^4} \right] e^{-\frac{x^2+y^2}{2\sigma^2}}$$

在数字图像上实现LoG



0	0	-1	0	0
0	-1	-2	-1	0
-1	-2	16	-2	-1
0	-1	-2	-1	0
0	0	-1	0	0


- LoG 因其形状，也称为Mexican hat
- 求和为0，即对平坦图像区域的响应为0
- 一个近似的卷积模版：体现主要的形状

$$\iint \nabla^2 G(x, y) dx dy = 0$$

LoG: 例子



(a)



(b)



(c)

(a) Lenna Image

(b) Gaussian模版卷积 (15×15)

(c) Laplacian模版卷积 (3×3)

分两步实现LoG，可以提供更大的灵活性更小的模版尺寸

LoG: 例子



(d)



(e)



(f)

(d) 将(c)中大于0的像素置1，其余置0

(e) 在二值图像 (d) 上检测边缘，使用形态学膨胀方法

(f) 结果显示

几个特点:

(1) 正确检测到的边缘: 单像素宽度, 定位准确

(2) 形成许多封闭的轮廓 (spaghetti, 意大利面条), 这是一个主要的问题

(3) 需要更加复杂的算法检测过零点



多模态人工智能系统
全国重点实验室

State Key Laboratory of
Multimodal Artificial Intelligence Systems

MAIS

边缘检测

Canny边缘检测器



边缘检测准则

- 边缘检测准则：
 - 好的边缘检测性能：Good detection
对边缘的响应大于对噪声的响应
 - 好的定位性能：Good localization
其最大值应接近边缘的实际位置
 - 低的错误检测率：Low false positives
在边缘附近只有一个极值点


MAIS





Canny边缘检测器

算法基本过程：



NMS: Non-Maxima Suppression

计算图像梯度：高斯函数的一阶导数

(1) 求图像与高斯平滑滤波器卷积:

$$S(x, y) = G(x, y, \sigma) * I(x, y)$$

σ 代表对图像的平滑程度

(2) 使用一阶有限差分计算偏导数的两个阵列:

$$D_x(x, y) \approx (S(x, y + 1) - S(x, y) + S(x + 1, y + 1) - S(x + 1, y))/2$$

$$D_y(x, y) \approx (S(x, y) - S(x + 1, y) + S(x, y + 1) - S(x + 1, y + 1))/2$$

相当于与模版进行卷积运算:

-1	1	1	1
-1	1	-1	-1

计算图像梯度：高斯函数的一阶导数


(3) 幅值和方位角:

$$M(x, y) = \sqrt{D_x(x, y)^2 + D_y(x, y)^2}$$

$$\theta(x, y) = \arctan(D_y(x, y)/D_x(x, y))$$

M 代表梯度幅值的大小，在存在边缘的图像位置处， M 的值变大，图像的边缘特征被“增强”。

如何检测边缘？





- 局部极值周围存在相近数值的点

非极大值抑制 NMS

非极大值抑制 (NMS: Non-Maxima Suppression)

- 对于梯度幅值图像上任意一点，判断其是否是梯度方向上的极大值点：如是，则保留；否则，不作为边缘点。
- 经非极大值抑制后的边缘具有单像素宽度。




- 在梯度方向的沿线上检测该点是否为局部极大值
- 简化的情形，只使用4个方向： $\{0, 45, 90, 135\}$

对NMS结果进行二值化


对上述NMS结果进行双阈值化处理 ($T_1 < T_2$) :

- 小的阈值 T_1 :
 - 较多边缘点 E_1 (蓝色)
 - 较多错误检测
- 大的阈值 T_2 :
 - 较少边缘点 E_2 (红色)
 - 较多空隙



边缘连接

1. 将 E_2 中相连的边缘点输出为一幅边缘图像 E 。
2. 迭代：在 E 中逐一定位未被访问过的像素，则 E_1 中处于该像素邻域的像素被合并到 E ，直至所有像素均被访问过。
3. 将 E 作为结果输出。



Canny算子：流程



原始图像



原始图像经过Gauss平滑

Canny算子：流程



梯度幅值图像



梯度幅值经过非极大值抑制

Canny算子：流程



低阈值边缘图像



高阈值边缘图像



Canny输出边缘图像










使用Canny算子需要注意的问题



- Canny算子的优点：
 - 参数较少
 - 计算效率
 - 得到的边缘连续完整
- 参数的选择：
 - Gauss滤波的尺度
 - 双阈值的选择($LOW = HIGH * 0.4$)

MAIS






渐增高斯滤波模版的尺寸



渐增双阈值的大小，保持 $\text{low} = \text{high} * 0.4$



AIS





多模态人工智能系统
全国重点实验室








State Key Laboratory of
Multimodal Artificial Intelligence Systems

MAIS

特征点检测/角点检测



不同类型的角点



提取点特征的作用

- 图像的点特征是许多计算机视觉算法的基础：使用特征点来代表图像的内容
 - 运动目标跟踪
 - 物体识别
 - 图像配准
 - 全景图像拼接
 - 三维重建



什么是好的角点检测算法?

- 检测出图像中“真实的”角点
- 准确的定位性能
- 很高的重复检测率（稳定性好）
- 具有对噪声的鲁棒性
- 具有较高的计算效率





MAIS


特征点检测/角点检测

Harris角点检测




Harris角点检测基本思想


- 从图像局部的小窗口观察图像特征
- 角点定义 $\leftarrow$ 窗口向任意方向的移动都导致图像灰度的明显变化




Harris角点检测基本思想



平坦区域:
任意方向移动,
无灰度变化



边缘:
沿着边缘方向移
动, 无灰度变化



角点:
沿任意方向移动,
明显灰度变化

Harris检测：数学表达

将图像窗口平移 $[u, v]$ 产生灰度变化 $E(u, v)$


$$E(u, v) = \sum_{x, y} w(x, y) [I(x + u, y + v) - I(x, y)]^2$$

窗口函数

平移后的
图像灰度


图像灰度

窗口函数 $w(x, y) =$



1 in window, 0 outside

或



Gaussian

Harris检测：数学表达

$$E(u, v) = \sum_{x, y} w(x, y) [I(x + u, y + v) - I(x, y)]^2$$

$$I(x + u, y + v) = I(x, y) + I_x u + I_y v + O(u^2 + v^2)$$

$$\Rightarrow E(u, v) = \sum_{x, y} w(x, y) [I_x u + I_y v + O(u^2 + v^2)]^2$$

$$(I_x u + I_y v)^2 = I_x^2 u^2 + 2I_x I_y uv + I_y^2 v^2$$

$$= (u, v) \begin{pmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{pmatrix} \begin{pmatrix} u \\ v \end{pmatrix}$$

Harris检测：数学表达

于是对于局部微小的移动量 $[u, v]$ ，可以近似得到下面的表达：

$$E(u, v) \cong (u, v)M \begin{pmatrix} u \\ v \end{pmatrix}$$

其中 M 是 2×2 矩阵，可由图像的导数求得：

$$M = \sum_{x,y} w(x, y) \begin{pmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{pmatrix}$$


Harris检测：数学表达

窗口移动导致的图像变化：实对称矩阵 M 的特征值分析

$$E(u, v) \cong (u, v)M \begin{pmatrix} u \\ v \end{pmatrix}$$

$\lambda_{\max}, \lambda_{\min} \leftarrow M$ 的特征值


$E(u, v)$ 的椭圆形式



Harris检测：数学表达

通过 M 的两个特征值的大小对图像点进行分类:

如果 λ_1 和 λ_2 都很小,
图像窗口在所有方向上
移动都无明显灰度变化





Harris检测：数学表达

定义：角点响应函数 R

$$R = \det M - k(\text{trace } M)^2$$

$$\det M = \lambda_1 \lambda_2$$


$$\text{trace } M = \lambda_1 + \lambda_2$$

(k – empirical constant, $k = 0.04-0.06$)


MAIS



R 的等高线图 ($k = 0.2$)




R 的等高线图 ($k = 0.1$)



MAIS





R 的等高线图 ($k = 0.05$)



Harris检测：数学表达

- R 只与 M 的特征值有关
- 角点： R 为大数值正数
- 边缘： R 为大数值负数
- 平坦区： R 为小数值





Harris角点检测

- 算法:
 - 对角点响应函数 R 进行阈值处理:
$$R > \text{threshold}$$
 - 提取 R 的局部极大值

MAIS




Harris角点检测：流程




Harris角点检测：流程

角点响应函数R



Harris角点检测：流程

提取R的局部极值



Harris角点检测：流程



Harris角点检测：小结


- 沿方向 $[u, v]$ 的平均灰度变化可以表达成双线性形式：

$$E(u, v) \cong (u, v) M \begin{pmatrix} u \\ v \end{pmatrix}$$

- 使用 M 的特征值表达图像点局部灰度变化的情况，定义角点响应函数：


$$R = \det M - k(\text{trace } M)^2$$

- 一个好的角点沿着任意方向移动都将导致明显的图像灰度变化，即： R 具有大的正数值。



Harris角点的性质

- 旋转不变性:



椭圆转过一定角度但是其形状保持不变
(特征值保持不变)

角点响应函数 R 对于图像的旋转具有不变性



Harris角点的性质

- 对于图像**灰度**的仿射变化具有部分的不变性

✓ 只使用了图像导数 => 对于灰度平移变化不变


$$I \rightarrow I + b$$

✓ 对于图像灰度的尺度变化: $I \rightarrow a I$




Harris角点的性质

- 对于图像几何尺度变化不具有不变性:



这几个点被分类为边缘点



图像缩小




角点!



参考文献

- 1 J. Canny, A Computational Approach To Edge Detection. IEEE Trans. Pattern Analysis and Machine Intelligence. 1986, (8): 679–714.
- 2 C. Harris and M. Stephens, A Combined Corner and Edge Detector. Proc. of 4th Alvey Vision Conference, 1988



小节

- 1、边缘检测相关概念
- 2、微分算子
- 3、Canny边缘检测算法


MAIS



课后练习

- (1) 试编程实现Canny边缘检测算法，并在下图上进行测试。
- (2) 试编程实现Harris角点检测算法，并在下图上进行测试。





MAIS

谢谢!

